

一、数据检查与清洗

读取数据并进行时间格式转换后，截取到 2025 年的房屋转售数据共有 25086 行和 11 列，其中包括 1 个时间变量(month)，3 个数值变量(floor_area_sqm、resale_price、lease_commence_date)，7 个类别变量(town、flat_type、flat_model、storey_range、remaining_lease、block、street_name)。

随机抽取 5 行数据展示如图 1：

	month	town	flat_type	block	street_name	storey_range	floor_area_sqm	flat_model	lease_commence_date	remaining_lease	resale_price
216803	2025-09-01	TAMPINES	4 ROOM	842B	TAMPINES ST 82	04 TO 06	107.0	Model A	1995	68 years 05 months	718000.0
210060	2025-12-01	PUNGGOL	2 ROOM	232C	SUMANG LANE	04 TO 06	38.0	2-room	2018	92 years	360000.0
197296	2025-10-01	ANG MO KIO	3 ROOM	328	ANG MO KIO AVE 3	01 TO 03	73.0	New Generation	1978	52 years	410000.0
205909	2025-11-01	HOUGANG	4 ROOM	936	HOUGANG ST 92	04 TO 06	100.0	Model A	1998	71 years 04 months	570000.0
218934	2025-01-01	WOODLANDS	4 ROOM	347	WOODLANDS AVE 3	10 TO 12	84.0	Simplified	1988	62 years 06 months	537000.0

图 1

截取后的数据没有缺失值；重复行数有 13 行，经核对检查确认后已删除，删除后行数为 25073 行；核心数值 resale_price 和 floor_area_sqm 用箱线图（图 2）做异常值检查，发现存在 653 条 113 万到 165 万的高价房源，48 条 169 m²到 195 m²的大面积房屋，核对后发现这在房屋转售中是真实现象，保留。




图 2

对时间变量和三个类别变量做数值化处理，month 提取月份，flat_type 做序数编码后新增 flat_type_num，storey_range 取中值后新增 storey_mid，remaining_lease 转为纯数字。

二、业务问题分析

通过查看目标变量 resale_price 直方图（图 3）可知，转售房价呈现明显右偏分布，价格主要集中在 40 万至 80 万之间，少数价格在 112 万甚至 150 万，经对

数变换后，转售房价接近正态分布。在后续线性回归模型建模中，需要对 resale_price 进行对数变换，以缓解偏态对模型的影响。




图 3

从图 4 来看，转售房中新旧房源都有，主要集中在中低楼层、中小户型。根据图 5 可以发现，面积与转售价格之间呈明显正相关，房屋面积越大，转售价格总体越高，是影响价格的重要因素；剩余租约与转售房价之间也呈一定正相关关系，租约越长通常对应转售价格更高；相比之下，楼层高度与转售价格的关系相对较弱，不同楼层的价格分布较为分散，仅呈现轻微上升趋势。




图 4




图 5

图 6 是类别变量直方图，可以看出 TAMPINES 和 SENGKANG 转售房源最多，4 房式是主流房型，房屋以 Model A 和 Improved 为主。从图 7 中可以看到，转售价格受房型和地区双重影响，各地区都存在高价离群点，Bukit Timah 转售

价格中位数较高，Queenstown 转售价格波动最大，转售价格随房型增大而上涨。




图 6




图 7

图 8 显示 floor_area_sqm 和 flat_type_num 与 resale_price 的相关系数分别为 0.66 和 0.67，是影响转售价格的关键因素；remaining_lease 和 storey_mid（系数

分别为 0.39 和 0.37) 是影响转售价格的次要因素。




图 8

三、特征工程与数据准备

数据集中无缺失值，对完全重复行进行删除以消除冗余；针对面积与转售价格中出现的异常值，经分析确认是真实的高端转售房源，保留有助于模型学习大面积房源、特殊地段的价格规律。

对类别变量 town 进行独热编码，storey_range 取中值新增一列为 storey_mid，remaining_lease 转为纯数字。对数值特征执行 StandardScaler 标准化，以消除量纲影响。

根据图 8 和表 1 结果分析，floor_area_sqm 和 flat_type_num 存在明显的共线性 ($VIF > 10$)，在线性回归中剔除 flat_type_num，以确保模型参数估计的稳定性和解释性；在树模型中保留 flat_type 以追求预测精度。剔除 month_num，它与 resale_price 的相关性极低，仅为 0.03。

block 和 street 的类别非常多，并且与 town 存在信息重叠情况，为防止随机森林模型和梯度提升树模型过拟合，以及避免线性回归模型中出现“维度爆炸”

问题，剔除 block 和 street。

Feature	VIF
flat_type_num	12.537189
floor_area_sqm	12.433295
remaining_lease	1.119012
Storey_mid	1.085327
Month_num	1.001104

表 1

综上，最终进入模型的特征是 floor_area_sqm, remaining_lease, storey_mid, flat_type, town, flat_model。进入各模型的具体特征如表 2 所示。

模型	数值特征	类别特征
线性回归	floor_area_sqm、remaining_lease、storey_mid	town
随机森林	floor_area_sqm、remaining_lease、storey_mid	flat_type、town、flat_model
梯度提升树	floor_area_sqm、remaining_lease、storey_mid	flat_type、town、flat_model

表 2

四、建模与验证

(1) 模型选择

本研究中，采用线性回归、随机森林、梯度提升树三种模型。

线性回归模型是最简单的模型，可以用它来建立预测基准，而且这个模型的可解释性强，它可以量化各特征的边际影响，直观的告诉我们“面积每增加 1 m²转售房价涨多少”，同时模型的训练速度也非常快。

房屋转售数据中存在非线性关系和很多复杂的交互，而随机森林模型可以自动捕捉非线性关系以及特征之间的交互作用，不需要担心多重共线性问题，在样本特征维度较高时仍能高效训练模型，并且无需特征标准化，对异常值也不敏感，不容易过拟合，模型表现非常稳健，能稳定捕获房价波动规律。

梯度提升树预测精度高。与随机森林模型相比，它同样可以自动处理特征间的非线性关系和交互作用，不同的是，梯度提升树采用迭代拟合残差的方式来逐步修正预测误差，所以它往往能达到比随机森林更高的精度上限，可以捕捉极细微的市场定价差异。

(2) 交叉验证与超参数调优

为平衡计算成本与估计方差，本研究采用 5 折交叉验证作为统一的模型交叉验证方案（shuffle=True，RANDOM_SEED = 42），以消除数据排列偏差并保证结果可复现。

线性回归直接使用 5 折交叉验证评估其稳定性（CV R²=0.8967±0.0018，标准差极小，说明模型对不同数据折叠均表现一致）。

随机森林采用 GridSearchCV，对树的数量、深度及叶节点样本数进行 27 种组合，共训练 135 个模型。最优参数为 n_estimators=300, max_depth=None, min_samples_leaf=1，最优 CV R²=0.9493，该参数表明深层分裂能更好捕捉细粒度规律，且 Bagging 集成有效控制了过拟合风险。

梯度提升树同样采用 GridSearchCV，针对学习率、树深及行列采样比例等 108 种组合，进行 540 次训练。最优参数为 n_estimators=300, learning_rate=0.1, max_depth=7, subsample=0.8, colsample_bytree=0.8，最优 CV R²=0.9573。该参数证明在每棵树训练时引入随机性对模型多样性及泛化能力具有显著的增强作用。

五、结果分析

(1) 比较和评价模型性能

本研究对三种模型在验证集与测试集上的表现进行了综合评估，结果如表 3 所示：梯度提升树模型表现最优，所有核心指标均大幅领先。其测试集 R² 为 0.9627，且 MAPE 仅为 4.19%，MAE 为 27714，这意味着该模型对单套房屋的估价偏差平均仅约为 2.77 万新元，具有极高的参考价值。

模型	CV R ²	R ²	Adj R ²	MSE	RMSE	MAE	MAPE
线性回归	0.8967±0.0018	0.8923	0.8916	4,522,812,596	67,252	49,773	7.56%
随机森林	0.9493	0.9550	0.9545	1,888,517,039	43,457	29,197	4.40%
梯度提升树	0.9573	0.9627	0.9622	1,567,633,399	39,593	27,714	4.19%

表 3

从图 9 看，梯度提升树模型预测点最贴合对角线，残差分布对称且集中，有效克服了线性回归模型在高价区的预测偏差。图 10 显示，训练与验证得分随样本量增加而紧密靠拢并趋于平稳，这证明模型已充分收敛且无过拟合风险。

此外，线性回归标准差仅 ± 0.0018 ，再次证实了数据的高质量及评估框架的稳健性。综上，梯度提升树在预测精度与泛化性上达到最优平衡，是辅助购房决策的核心模型。




图 9




图 10

(2) 特征重要性

图 11 展示了影响梯度提升树模型预测结果的重要特征，在聚合维度中 Town 的权重最高且超过 0.5，说明城镇是决定房屋转售价格的首要因素，而楼层和剩余租约对全局价格的影响相对较小。在原始特征中，2 房和 3 房的影响力最高，表明房型是决定价格区间的关键因素，稀缺 Flat Model（如 DBSS）和特定地段（如大巴窑）显著影响模型预测。




图 11

(3) 购房建议

● 刚需型—— 房型是关键

根据梯度提升树的特征重要性，房型（Flat Type）是仅次于地段的最强价格驱动因素。利用梯度提升树计算不同房型对价格的具体影响得出：

- 2 ROOM → 价格最低，适合预算极有限的首次购房者
- 4 ROOM → 性价比与居住面积达到最优平衡
- 5 ROOM → 在 4 房基础上显著溢价，但家庭居住空间大幅提升
- EXECUTIVE → 总价最高，但转售流动性与保值能力最强

结论：“大房型”才是保值核心！建议刚需家庭优先锁定 4 房或 5 房，在总价可控的前提下尽量选择更大房型，抗跌性与转售流动性均更强。

● 投资型—— 关注核心城镇与稀缺 Flat Model

梯度提升树的聚合维度中，城镇重要性高达约 52%，Flat Model 约 16%，两者合计超过总影响的三分之二。利用梯度提升树通过非线性学习捕捉地段和稀缺性溢价得出：

- Bukit Timah → 全岛溢价最高地段，稀缺性强
- Queenstown → 中心地段，交通便利，历史成交活跃
- Bishan / Toa Payoh → 核心地段，均衡保值，需求稳定
- Bukit Merah → 靠近市区，升值潜力持续受关注
- DBSS / Type S1 等稀缺 Flat Model 较普通 Flat Model 溢价显著

结论：若预算充足，优先考虑 Bukit Timah、Queenstown、Bishan 等核心地段，或 DBSS 等稀缺 Flat Model，长期资产保值性更强。

● 性价比型—— 寻找价值洼地

避开梯度提升树模型中的高权重热门区域，选取中等地段降低总价，选择中低楼层，就可以买大面积房屋。综合以上得出：

- 地段策略 → 选择 Yishun、Woodlands、Bedok 等非热门但配套成熟的地区，中位成交价显著低于全岛均值
- 楼层策略 → 选择 6-12 层中低楼层，与高楼层相比可以节省总价，节省下来的价钱可置换至更大面积或更好地段
- 房型策略 → 在上述地段中选择 4 房或 5 房，以同等甚至更低总价获得更大居住空间

结论：在 Yishun、Woodlands、Bedok 等地选择中楼层的 4 房或 5 房，可以在预算有限的情况下获得最大居住空间，极大提升居住品质。

(4) 方案总结

本研究构建了完整的房价预测流程。具有以下核心优势：

一、通过比较线性回归、随机森林和梯度提升树三种模型在可解释性与预测能力之间取得平衡，并最终选择梯度提升树作为最佳模型，以捕捉房价数据中的非线性关系与特征交互效应。

二、利用 sklearn Pipeline 将数据预处理（StandardScaler、OneHotEncoder）与模型训练封装，避免数据泄露，并通过 joblib 实现模型保存，同时借助 Streamlit 构建交互式预测系统。

三、评估方面采用 5 折交叉验证与测试集双重验证，并结合 R^2 、RMSE、MAE、MAPE 及可视化分析进行综合评估。最终模型测试集 R^2 达 0.9627，MAPE 为 4.19%，预测精度较高。

本研究仍存在一定局限性：

一、数据局限于 2025 年单年度，缺乏长期的市场变化信息，存在时效性风险。

二、block 和 street_name 因类别过多未纳入模型，地理信息特征没有被充分利用，微观位置差异没有被捕捉，导致模型无法捕捉同一区域内的价格差异。

三、数据中没有引入 MRT 距离、学校排名、商场数量等外部特征，房价缺少外部的价格驱动因素，模型预测能力有限，难以解释地段价值。

三、模型未考虑宏观经济因素（如利率或政策调控），可能影响预测稳定性。

四、梯度提升树虽然预测效果较好，但模型可解释性相对有限。

在下一步研究中，可以引入地理信息特征和外部特征，增强模型对区位价值的刻画。同时扩展至多年份数据，结合时间序列特征以提升模型对市场周期变化的适应能力。